

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»**

**Отчёт по лабораторной работе №2
«Стохастические методы оптимизации негладких функций»**

Выполнил студент группы j3213:

Семёнов Никита, 467414

Санкт-Петербург

2026

Цель исследования

Познакомиться с двумя стохастическими алгоритмами оптимизации, которые отлично справляются с негладкими и разрывными функциями. Научиться вычислять целевую функцию с помощью специального типа данных — «конструктивного числа». Проанализировать, как ведут себя эти методы на классических тестовых функциях и функции с округлением, сравнить их с алгоритмами из предыдущей работы (по скорости, затратам памяти, точности) и разобраться в их реальных преимуществах и недостатках.

Задачи работы

Для исследования были выбраны два мощных стохастических подхода: Имитация отжига (Simulated Annealing) и Рой частиц (Particle Swarm Optimization). Чтобы было с чем сравнивать результаты, мы используем алгоритм Нелдера-Мида (Nelder-Mead) из первой лабораторной. Для гладких функций дополнительно применяются классические Градиентный спуск (Gradient Descent) и метод Ньютона (Newton). На сложных функциях (Eggholder и разрывная Desmos) градиентные методы не тестируются (отмечены в таблицах как N/A), так как для их работы обязательно нужны гладкие градиенты и матрица Гессе.

Теоретическая справка и используемые алгоритмы

Зачем вообще нужны стохастические методы?

Классические градиентные подходы опираются на локальную производную, из-за чего они легко могут «застрять» в ближайшем локальном минимуме, думая, что нашли идеальное решение. А если функция имеет разрывы (скачки), производная вообще не существует. Стохастические (вероятностные) алгоритмы решают эту проблему: они используют случайность для глобального исследования пространства, легко перепрыгивают через неровности и работают без аналитических производных.

Краткое описание используемых методов:

- **Simulated Annealing (Имитация отжига, SA)** — это вероятностный алгоритм, вдохновлённый физическим процессом охлаждения металла. На каждой итерации алгоритм смещается в случайную точку. Если новое состояние лучше

— алгоритм его принимает. Если хуже — всё равно может принять, но с определённой вероятностью, которая зависит от «температуры». В начале поиска температура высокая, что позволяет выпрыгивать из локальных ям, но по мере остывания алгоритм становится более строгим.

- **Particle Swarm Optimization (Метод роя частиц, PSO)** — популяционный алгоритм, моделирующий поведение стаи птиц. В пространстве поиска перемещается множество независимых «частиц». Каждая частица запоминает своё лучшее найденное положение и знает о лучшем положении всей стаи. Вектор скорости частицы постоянно корректируется с учётом этих ориентиров, заставляя рой быстро стягиваться к глобальному минимуму.
- **Градиентный спуск (Gradient Descent)** — метод локального поиска, который всегда шагает в сторону наискорейшего убывания функции (антиградиента).
- **Метод Ньютона (Newton's method)** — мощный алгоритм, который использует информацию не только о наклоне (градиенте), но и о кривизне поверхности (матрица Гессе), что даёт невероятно быструю сходимость на гладких рельефах.
- **Метод Нелдера-Мида (Nelder-Mead)** — безградиентный метод, который «перекачивает» многогранник (симплекс) по поверхности в поисках локального минимума.

Расширение конструктивного числа

В этой работе мы продолжаем использовать интервальный тип данных $[a, b]$, но добавляем в него новые операции: возведение в квадрат, модуль, корень, синус, косинус и округление (`round`). Для расчёта синуса оцениваются границы интервала и критические точки (± 1) внутри него. При вычислении модуля учитывается, пересекает ли интервал ноль. Округление работает как ступенчатая функция. Координаты поиска для SA и PSO берутся как центральные точки, а вычисления идут через `ConstructiveNumber` с заданной погрешностью ϵ .

Тестовые функции

- **Функция Растригина (Rastrigin):** $f(x,y)=20+x^2+y^2-10(\cos(2\pi x)+\cos(2\pi y))$. Имеет огромное количество локальных впадин и глобальный минимум $f(0,0)=0$. Идеальна для проверки способности метода избегать застреваний.

- **Функция Химмельблау (Himmelblau):** $f(x,y)=(x^2+y-11)^2+(x+y^2-7)^2$.
Гладкая функция с несколькими равными глобальными минимумами, равными нулю. Отлично подходит для сравнения с градиентными методами.
- **Функция Эггхолдера (Eggholder):** $f(x,y)=-(y+47)\sin(\sqrt{|x/2+y+47|})-x\cdot \sin(\sqrt{|x-(y+47)|})$. Очень сложный, «изрезанный» рельеф с эталонным минимумом около -959.6407.
- **Разрывная функция Desmos:** $f(x,y)=((x(\text{round}(\sin(10y))+2))^2+y-10)^2+(x+(y(\text{round}(\sin(7x))+2))^2-7)^2$. За счёт операции округления функция имеет ступенчатые разрывы, поэтому градиентные методы тут бессильны. Эталонный минимум практически равен нулю в точке (1.01018131, 0.81580354).

Оценка использования памяти

Мы используем единую функцию `_deep_size`, которая рекурсивно подсчитывает вес в байтах для всех возвращаемых алгоритмами структур (массивы истории, словари и т.д.).

Этапы выполнения

- Добавление новых математических операций (`sin`, `cos`, `abs`, `sqrt`, `round`) в структуру `ConstructiveNumber`.
- Программирование всех четырёх тестовых функций с унифицированным интерфейсом.
- Написание алгоритма Имитации отжига (SA) с правилом вероятностного принятия худших решений.
- Написание алгоритма Роя частиц (PSO) с отслеживанием индивидуальных (`pbest`) и глобальных (`gbest`) позиций.
- Интеграция методов из первой лабораторной работы (Nelder-Mead, Gradient Descent, Newton) для проведения сравнительных тестов.
- Сбор статистики, анализ влияния погрешности ϵ и сопоставление алгоритмов.
- Построение графиков сходимости и отрисовка траекторий движения частиц.

Полученные результаты и их анализ

Сводные результаты тестирования алгоритмов

Функция	Метод	Итерации	Вызовы f	Время, с	f(x)	Ошибка	Память, Б
Rastrigin-2	Simulated Annealing	5000	5001	1.08506	8.193e-04	8.193e-04	161311

Функция	Метод	Итерации	Вызовы f	Время, с	f(x)	Ошибка	Память, Б
Rastrigin-2	Particle Swarm	250	7530	0.855115	2.000e-14	2.000e-14	8962
Rastrigin-2	Nelder-Mead	57	281	0.0243911	24.8738	24.8738	2770
Himmelblau	Simulated Annealing	4000	4001	0.566798	4.355e-04	4.355e-04	129311
Himmelblau	Particle Swarm	250	7530	0.537151	7.198e-20	7.198e-20	8962
Himmelblau	Nelder-Mead	60	295	0.00650616	2.452e-16	2.452e-16	2866
Eggholder	Simulated Annealing	5000	5001	0.892172	-894.535	65.1056	161311
Eggholder	Particle Swarm	250	7530	0.682435	-786.526	173.115	8962
Eggholder	Nelder-Mead	85	419	0.0426077	-558.521	401.12	3666
Desmos-disc.	Simulated Annealing	4000	4001	0.962886	0.219458	0.219458	129311
Desmos-disc.	Particle Swarm	500	15030	1.87682	2.527e-14	2.527e-14	16962
Desmos-disc.	Nelder-Mead	105	522	0.0836063	552.552	552.552	4306

На мультимодальной функции Rastrigin метод PSO показал феноменальный результат, подобравшись практически к абсолютному нулю ($2 \cdot 10^{-14}$). SA тоже справился достойно, а вот локальный метод Nelder-Mead предсказуемо застрял в локальной яме ($f \approx 24.87$).

На гладкой Himmelblau алгоритмы PSO и Nelder-Mead легко нашли нули, а Имитация отжига завершила работу с малой погрешностью около $4.35 \cdot 10^{-4}$.

Сложнейшая функция Eggholder оказалась крепким орешком: ни один алгоритм не дошёл до идеального глобального минимума (-959.6407), но ближе всех подобрался SA (-894.54).

На разрывной Desmos-функции PSO снова одержал победу, найдя глобальный минимум ($2.53 \cdot 10^{-14}$), что ярко доказывает мощь популяционных алгоритмов на негладких ландшафтах, в то время как Nelder-Mead застрял на огромном значении 552.55.

Сравнение с алгоритмами из предыдущей лабораторной

Функция	Метод	Статус	Итер.	Вызовы	f(x)	Ошибка
Rastrigin-2	Simulated Annealing	OK	5.0e+03	5.0e+03	8.19e-04	8.19e-04
Rastrigin-2	Particle Swarm	OK	250	7.5e+03	2.00e-14	2.00e-14

Функция	Метод	Статус	Итер.	Вызовы	f(x)	Ошибка
Rastrigin-2	Gradient descent	OK	5.0e+03	5.0e+03	52.1092	52.1092
Rastrigin-2	Newton	OK	8	23	33.8283	33.8283
Himmelblau	Gradient descent	OK	17	18	1.69e-15	1.69e-15
Himmelblau	Newton	OK	5	11	3.07e-23	3.07e-23
Eggholder	Newton	N/A	-	-	-	-
Desmos-disc.	Gradient descent	N/A	-	-	-	-

(В выборке отсутствуют данные для негладких функций у GD/Newton)

Градиентный спуск и метод Ньютона работают невероятно быстро и точно на гладких поверхностях (как Himmelblau), где они могут использовать производные. Ньютон нашёл ответ всего за 5 итераций. Однако на Растригине они мгновенно скатываются в ближайшие локальные ямы. Это подтверждает правило: нет абсолютно универсального алгоритма. Градиентные методы идеальны для гладких поверхностей, а стохастические — для сложных и разрывных ландшафтов.




Анализ времени работы и количества вызовов

Алгоритм SA делает приблизительно один вызов целевой функции за итерацию (5000 шагов = 5001 вызов). PSO вынужден вычислять функцию для каждой отдельной частицы на каждом шаге. Из-за этого при роё из 30 частиц и 250 шагах получается свыше 7500 вызовов, а на функции Desmos — больше 15000. Таким образом, высокая точность роя частиц достигается ценой больших вычислительных затрат. Метод Ньютона на гладких задачах оказался самым быстрым и экономичным.




Анализ динамики погрешности ϵ

Чувствительность сильно зависит от топологии функции (при входной $\epsilon=10^{-8}$). Для гладких функций она остаётся стабильной. Для разрывной Desmos использование функции round создаёт огромные скачки ϵ , если точка поиска оказывается вблизи границы округления.




Ограничения исследования






Rastrigin показывает различие локального и глобального поиска: PSO постепенно собирает частицы около глобального минимума, тогда как локальные методы могут закрепиться в одной из многочисленных впадин.



У Himmelblau несколько равноценных глобальных минимумов. Разные алгоритмы могут прийти к разным точкам, но значение функции при успешной сходимости остаётся практически нулевым.



У Eggholder рельеф сложный и содержит большое количество локальных структур; найденная точка существенно зависит от характера глобального исследования и доступного бюджета вычислений.



Популяционный метод (Particle Swarm) блестяще справился с разрывной функцией, в то время как локальный подход (Nelder-Mead) потерпел полное фиаско.

Поскольку SA и PSO основаны на генерации случайных чисел, все результаты получены при фиксированном значении зерна генератора ($\text{seed} = 67$). Для статистически безупречного анализа необходимо проводить целую серию тестов с разными седами. Замеры памяти фиксируют только размер итоговых сохранённых данных (истории, массивов), а не пиковое потребление

оперативной памяти процессом. Градиентные методы на разрывных функциях не запускались чисто технически из-за отсутствия гладких аналитических производных.

Заключение

В ходе выполнения работы были успешно реализованы и протестированы стохастические алгоритмы Simulated Annealing и Particle Swarm Optimization. Их сопоставление с классическими подходами из первой лабораторной подтвердило важную закономерность: выбор инструмента должен диктоваться самой задачей.

Для простых и гладких поверхностей (таких как Himmelblau) нет ничего эффективнее методов, использующих производные — они находят оптимум за считанные шаги. Однако, когда мы сталкиваемся с мультимодальными (Rastrigin), глубоко изрезанными (Eggholder) или разрывными (Desmos) функциями, локальные градиентные алгоритмы терпят крах, застревая в первой же впадине. Именно в таких условиях стохастические методы раскрывают весь свой потенциал: метод роя частиц и имитация отжига способны глобально исследовать всё пространство и найти оптимальное решение даже там, где производную вычислить невозможно.